

# Relazione di Laboratorio Computazionale

Alessio Marchetti

Le parti in grassetto sono commenti generici o placeholder perchè QUESTA È UNA BOZZA!

## Abstract

In questa relazione prenderemo in considerazione il problema di estrarre campioni di valori casuali data una certa distribuzione di probabilità discreta. Supporremo di sapere generare variabili uniformi sull'intervallo  $[0, 1]$ , che verranno implementate operativamente come le variabili generate dalla libreria `numpy`.

Una prima soluzione del problema è quella di dividere  $[0, 1]$  in intervalli di lunghezza pari a ciascuna componente del vettore di probabilità, e scegliere il risultato in funzione dell'intervallo a cui appartiene una variabile uniforme. Questo presenta diversi inconvenienti: il metodo infatti richiede un numero di somme proporzionale al numero di componenti del vettore di probabilità. Questo potrebbe essere intrattabile quando molto grande. Inoltre spesso il vettore di probabilità è noto solo a meno di un coefficiente di normalizzazione, il cui calcolo richiederebbe di nuovo  $O(n)$  somme.

Uno dei metodi più utilizzati per ovviare a questi problemi è il metodo di Monte Carlo (abbreviato spesso con MCMC, Markov Chain Monte Carlo), che consiste nella simulazione di una camminata su una catena di Markov con distribuzione invariante la distribuzione data. Dopo un numero sufficiente di step, la frequenza di visita di un nodo sarà arbitrariamente vicina a quella voluta. In questo caso però il numero di passi necessari ad una determinata distribuzione non è noto a priori ed è di difficile calcolo.

Si andrà dunque a presentare l'algoritmo di Propp-Wilson, una modifica del MCMC che ha il vantaggio di ottenere la distribuzione esatta e di terminare una volta raggiunta questa. Applicheremo tale algoritmo al modello di Ising, una modellizzazione del comportamento magnetico della materia.

## 1 Il modello di Ising

Sia  $G = (V, E)$  un grafo. I vertici andranno a rappresentare i singoli atomi di un materiale, e gli archi indicano quali atomi interagiscono fra loro. Ad ogni atomo viene quindi associato uno spin che può essere  $+1$  o  $-1$ . Una configurazione è quindi una funzione  $f: V \rightarrow \{+1, -1\}$ . A ciascuno di questi modelli si associa

l'energia

$$H(f) = \sum_{(x,y) \in E} f(x)f(y)$$

. Inoltre viene dato un parametro reale del sistema  $\beta \geq 0$  detta temperatura inversa. Il modello di ising associa ad ogni configurazione  $f \in \{+1, -1\}^V$  la probabilità

$$\pi(f) = \frac{1}{Z} \exp(-\beta H(f))$$

Dove  $Z$  è il coefficiente di normalizzazione pari a

$$Z = \sum_{f \in \{+1, -1\}^V} \exp(-\beta H(f))$$

L'obiettivo che ci prefiggiamo è quello di estrarre un campione da  $\{+1, -1\}^V$  con probabilità  $\pi$ .

## 2 Metodo di Monte Carlo

### Non so se ha davvero senso questa parte

Come prima cosa, data una distribuzione  $\pi$  su un insieme  $\Omega$ , cerchiamo una matrice di transizione  $P$  per una catena di Markov omogenea che abbia  $\pi$  come misura invariante. Per farlo chiediamo una condizione più forte su  $P$ , cioè la reversibilità, ovvero si vuole che  $\pi(i)P_{i,j} = \pi(j)P_{j,i}$ . Se la matrice  $P$  è irriducibile e aperiodica, data una distribuzione iniziale  $\pi_0$ , la distribuzione di probabilità dopo  $n$  passi  $\pi_n = \pi_0 P^n$  converge a  $\pi$

Cerchiamo allora le matrici del tipo  $P_{i,j} = A_{i,j}Q_{i,j}$  per  $i \neq j$ , dove la matrice  $Q$  è irriducibile e viene detta matrice generatrice dei candidati, e  $A$  è da terminare in modo tale che  $P$  abbia le proprietà richieste e  $0 \leq A \leq 1$ . Le componenti  $P_{i,i}$  sono determinate in maniera tale che  $P$  sia stocastica. A livello di interpretazione si può pensare che a ogni step si sceglie vertice candidato a cui passare con probabilità dettata da  $Q$  e poi si esegue il passaggio con probabilità dettata da  $A$ , altrimenti si rimane nel vertice di partenza. Per questo motivo  $A$  è la matrice delle probabilità di accettazione.

Generalmente si sceglie  $A$  della forma

$$A_{i,j} = \frac{S_{i,j}}{1 + T_{i,j}}$$

con

$$T_{i,j} = \frac{\pi(i)Q_{i,j}}{\pi(j)Q_{j,i}}$$

e  $S$  una matrice simmetrica. L'algoritmo di Metropoli-Hastings sceglie

$$A_{i,j} = \min(1, \frac{\pi(j)}{\pi(i)})$$

. In questo modo si determina una  $P$  con tutte le proprietà richieste.

**Forse un qualcosa sul Gibbs Sampler?**

### 3 Coupling from the past

In questa sezione svilupperemo un metodo per estrarre un campione con una probabilità esatta  $\pi$ , data  $P$  una matrice di transizione irriducibile e aperiodica su un insieme finito di stati  $S = \{s_1, \dots, s_n\}$  e con probabilità invariante  $\pi$ . Possiamo associare alla catena di Markov definita da  $P$  una funzione di transizione

$$f: S \times [0, 1] \longrightarrow S$$

tale che se  $U$  è una variabile uniforme sull'intervallo  $[0, 1]$ , allora

$$\mathbb{P}[f(s_i, U) = s_j] = P_{i,j} \quad \forall s_i, s_j \in S.$$

Questo può essere fatto, per esempio **nel modo ovvio**.

Siano  $U_n$  variabili uniformi su  $[0, 1]$  per ogni  $n \in \mathbb{Z}$ . Costruiamo allora delle sequenze  $X_m^r(i)$  con  $i = 1, \dots, n$ ,  $r \leq 0$  e  $m \geq r$  interi nel modo seguente:

$$X_r^r(i) = s_i$$

$$X_{m+1}^r(i) = f(X_m^r(i), U_m).$$

Sia ora

$$\tau^- = \max\{r \mid X_0^r(1) = \dots = X_0^r(n)\}$$

e definiamo  $Y = X_0^{\tau^-}(1)$ . Vogliamo verificare che  $Y$  ha distribuzione pari a  $\pi$ .

**Probabilmente questo ci va.**

**Probabilmente ci vanno anche dei controesempi per dire che il coupling in the future non funziona e che gli  $U$  devono essere sempre gli stessi, c'è su Haggstrom pp.81-82.**

**Mettere i disegni che sono strabelli?**

### 4 Sandwiching

Il metodo presentato sopra è funzionante e risolve gli scopi che ci eravamo prefissi, tuttavia simulare tutte le  $n$  catene di Markov è praticamente impossibile per  $n$  grandi. In questa sezione ci occuperemo di migliorare il metodo per renderlo computazionalmente più leggero.